

# Les méthodes d'appariement (Propensity Score Matching - PSM)

Introduction aux méthodes d'évaluation d'impact  
des politiques publiques

Philippe De Vreyer

Quand les employer?

# Quand l'employer?

Une des méthodes disponibles lorsque :

1. Les individus traités (ou participants) et les non traités (ou non participants) **n'ont pas été tirés au sort**

# Quand l'employer?

Une des méthodes disponibles lorsque :

1. Les individus traités (ou participants) et les non traités (ou non participants) **n'ont pas été tirés au sort**
2. On dispose de **beaucoup d'informations sur les membres de la population** (traités et non traités)


# Principe

# Rappel


- Tirage au sort : permet de s'assurer qu'en moyenne traités et non traités ont les mêmes caractéristiques.
- On peut alors attribuer au seul programme toute différence observée entre les deux groupes.

# Appariement

S'approcher des résultats du tirage au sort,  
en recherchant dans l'échantillon des non traités,  
les individus semblables aux individus traités.




Participants




Non participants







Participants




Non participants



Participants




Non participants




Homme, 27 ans,  
sans diplôme,  
célibataire sans  
enfant, habitant  
Rennes, au  
chômage depuis  
1 an, ne parle  
pas anglais

Participants




Non participants




Participants


Homme, 60 ans,  
bac, marié, deux  
enfants adultes,  
habitant  
Marseille, au  
chômage depuis  
15 mois, ne  
parle pas  
anglais



Non participants




Participants




Non participants





Participants



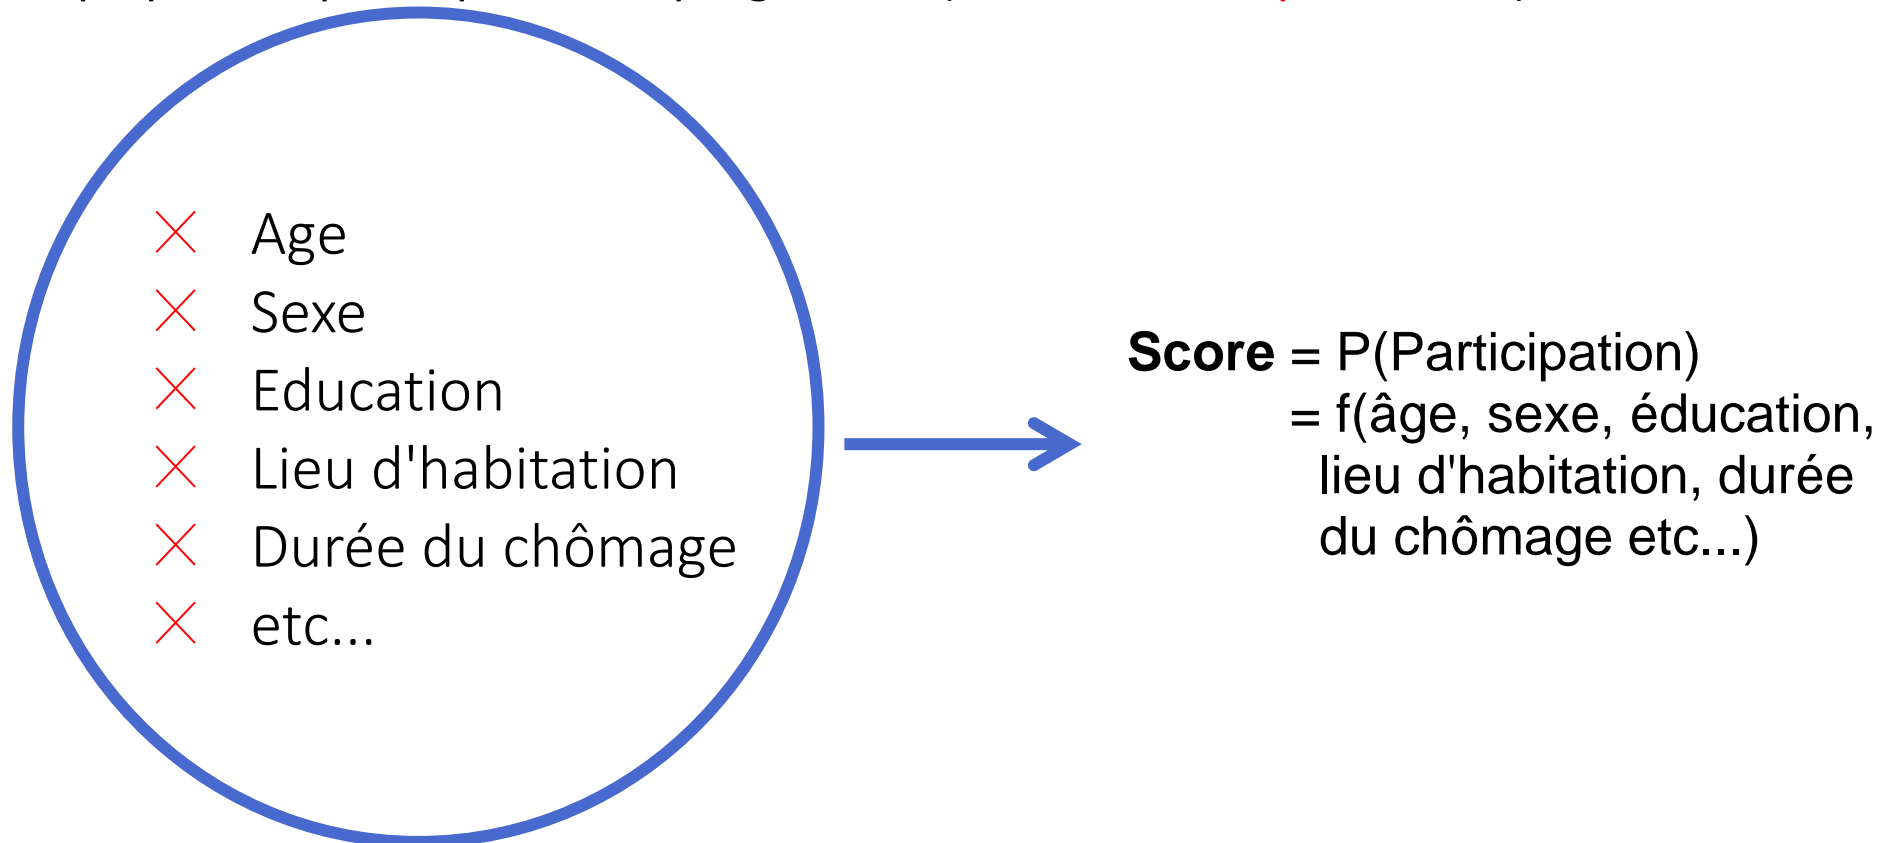
Non participants

Le score de propension :  
outil d'appariement


# Rosenbaum et Rubin (1983) *Biometrika*

Exemple : programme d'aide au retour à l'emploi à destination des chômeurs


Variables expliquant la participation au programme (**non modifiées par celui-ci**)






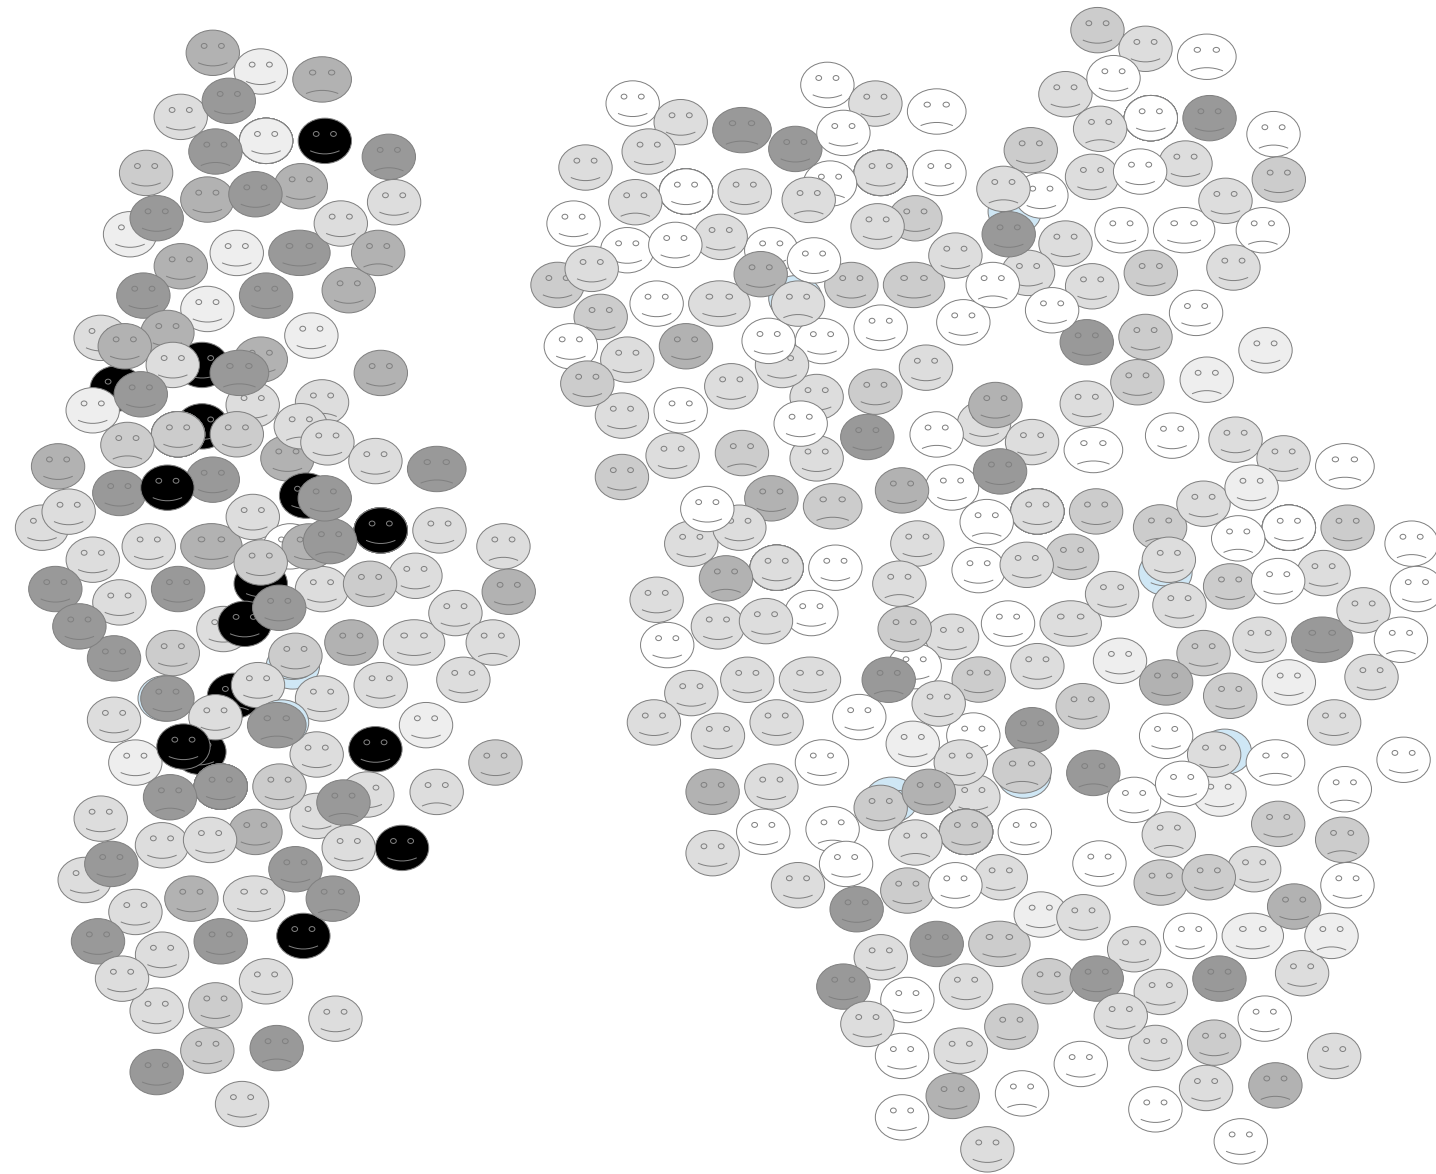


Score de propension




Participants + non participants






Participants + non participants

## Participants

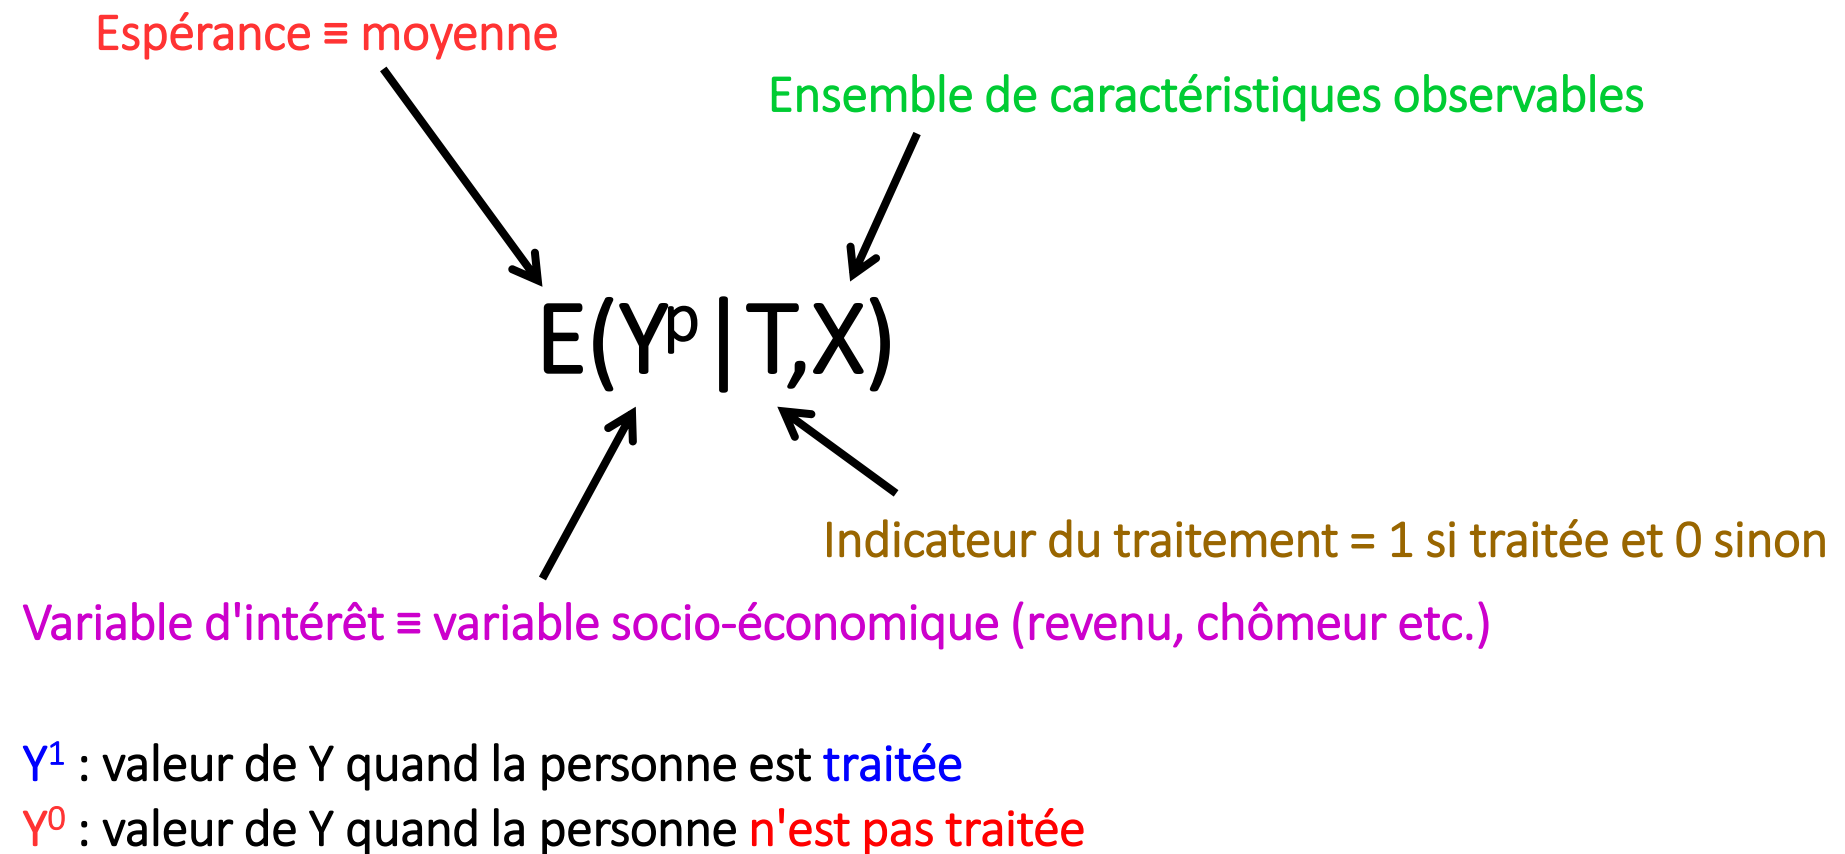


## Non participants



# Théorie

# Rappel des notations



# Exemple : programme d'aide au retour à l'emploi

- $Y$  = indicatrice prenant la valeur 1 si la personne est au chômage et 0 sinon
- $X$  = Sexe, âge, éducation, durée du chômage avant le programme etc.
- $E(Y^1 | T=1, X)$  = taux de chômage des personnes **traitées** de caractéristiques  $X$
- $E(Y^0 | T=0, X)$  = taux de chômage des personnes **non traitées** de caractéristiques  $X$



# Exemple : programme d'aide au retour à l'emploi

On s'intéresse également aux quantités suivantes :

- $E(Y^1 | T=0, X)$  = taux de chômage des personnes de caractéristiques  $X$  non traitées ( $T=0$ ) si elles avaient été traitées ( $Y^1$ )
- $E(Y^0 | T=1, X)$  = taux de chômage des personnes de caractéristiques  $X$  traitées ( $T=1$ ), si elles ne l'avaient pas été ( $Y^0$ )

# Effet du traitement

L'effet du traitement sur les personnes traitées est donné par la formule :

$$ATT = E(Y^1 | T=1, X) - E(Y^0 | T=1, X)$$

# Effet du traitement

L'effet du traitement sur les personnes traitées est donné par la formule :

$$ATT = E(Y^1 | T=1, X) - E(Y^0 | T=0, X)$$

$$+ E(Y^0 | T=0, X) - E(Y^0 | T=1, X)$$

$$= D + B$$

# Conditions d'emploi de la méthode

Trois conditions doivent être respectées pour pouvoir mettre en oeuvre la méthode PSM

## « Support » commun

Elle signifie que les individus traités doivent pouvoir être appariés avec des individus non traités ayant un score de propension proche.

# Condition d'équilibre des échantillons:

Les valeurs moyennes de  $X$  calculées dans chaque échantillon doivent être proches pour des valeurs proches du score de propension.

# Indépendance conditionnelle

$$E(Y^1 | T=1, X) = E(Y^1 | T=0, X)$$

$$E(Y^0 | T=1, X) = E(Y^0 | T=0, X)$$

# Indépendance conditionnelle

$$ATT = E(Y^1 | T=1, X) - E(Y^0 | T=0, X)$$

$$+ E(Y^0 | T=0, X) - E(Y^0 | T=1, X)$$

$$= D + B$$

Indépendance conditionnelle

$$E(Y^1 | T=1, X) = E(Y^1 | T=0, X)$$

$$E(Y^0 | T=1, X) = E(Y^0 | T=0, X)$$



Comment effectuer  
l'appariement ?

# Problème

Il est (quasiment) impossible de trouver deux personnes ayant exactement la même valeur du score de propension.

0,5789...

?

0,5751...

0,5769...

0,5781...

0,5783...

0,5788...

0,5791...

0,5845...


etc...

Traité à appaier

Non traités avec un score de propension proche

# Méthode du voisin le plus proche

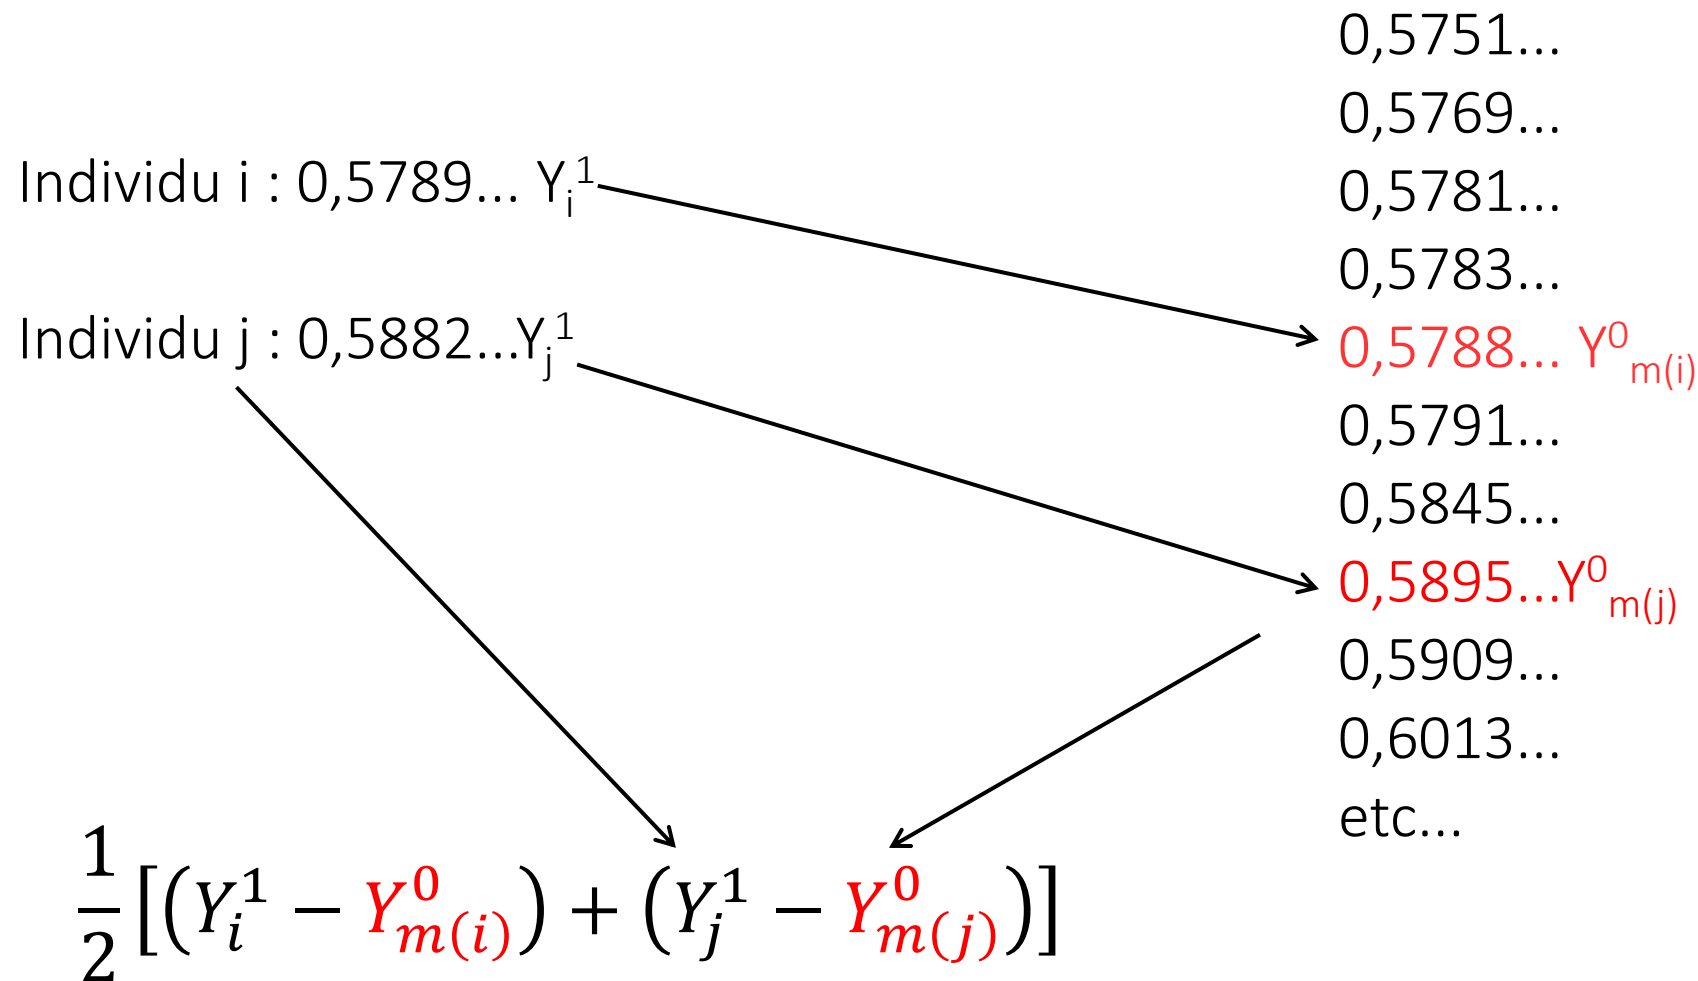
A priori le plus simple est de prendre l'individu non traité dont le score est le plus proche




Traité à apparier

Non traités avec un score de propension proche

# Calcul de l'effet du programme (méthode du voisin le plus proche)




# On peut faire (beaucoup) mieux




# Trop de place est laissée au hasard


Individu i : 0,5789...  $Y_i^1$   $\longrightarrow$  0,5788...  $\longrightarrow$   $Y_{m(i)}^0$



# Prendre des moyennes permet de réduire la place du hasard



# Prendre des moyennes permet de réduire la place du hasard



$$\frac{1}{2} \left[ Y_i^1 - \frac{1}{3} (Y_{m(i),1}^0 + Y_{m(i),2}^0 + Y_{m(i),3}^0) + Y_j^1 - \frac{1}{3} (Y_{m(j),1}^0 + Y_{m(j),2}^0 + Y_{m(j),3}^0) \right]$$



# Formule générale

Evaluation de l'effet du traitement

Pondération donnée à l'observation de la personne non traitée  $j$

$$ATT_{PSM} = \frac{1}{N_T} \sum_{i=1}^{N_T} \left[ Y_i^1 - \sum_{j \in m(i)} \omega(j) Y_j^0 \right]$$

Nombre de personnes **traitées**

Ensemble des **non traités** *appariés* à  $i$

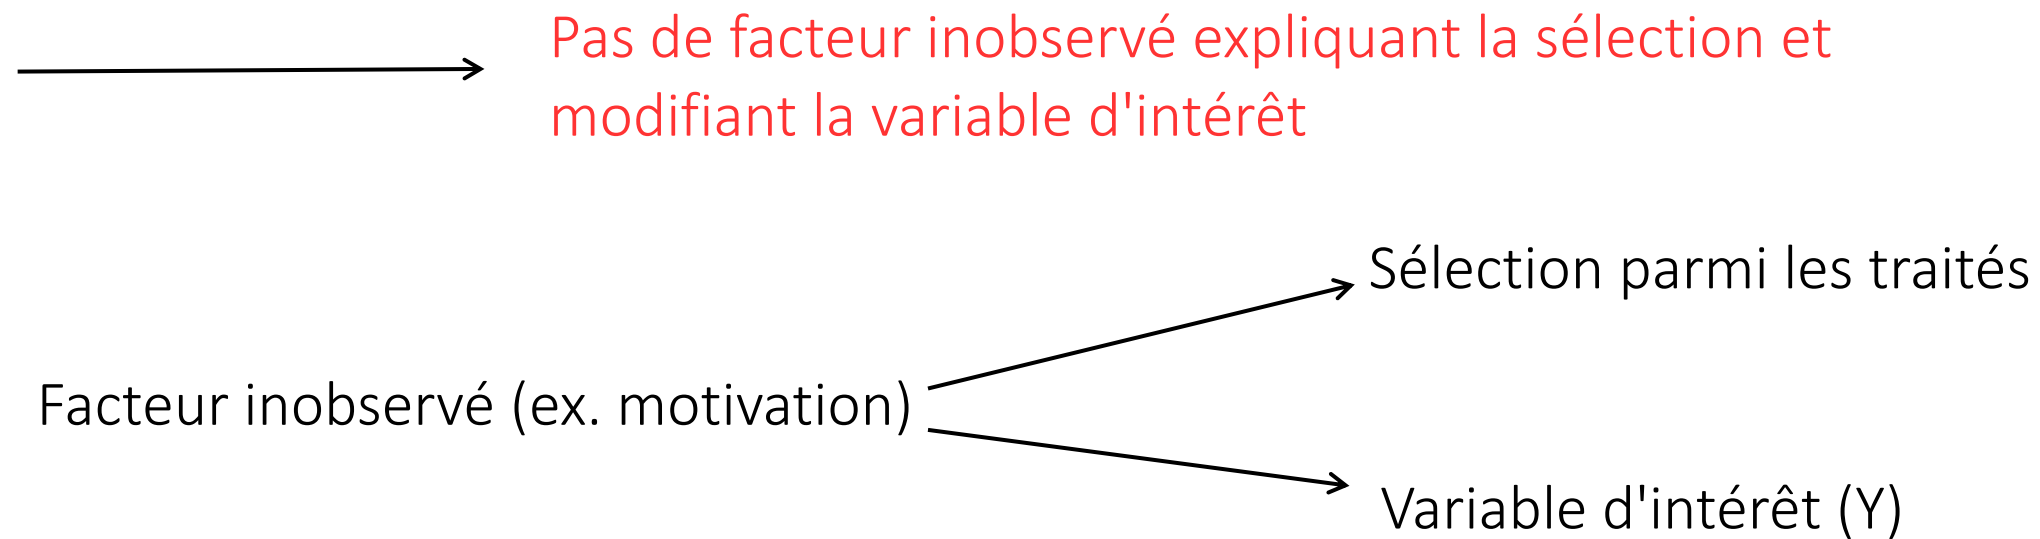
$$ATT_{PSM} = \frac{1}{N_T} \sum_{i=1}^{N_T} \left[ Y_i^1 - \sum_{j \in m(i)} \omega(j) Y_j^0 \right]$$

- La pondération  $\omega$  dépend de l'écart entre le score de l'individu traité et celui de l'individu qui lui est apparié.
- Un individu non traité peut-être apparié à plus d'un individu traité ( $m(k) \cap m(l) \neq \emptyset$ ).
- On peut choisir d'apparier chaque personne traitée à une (voisin le plus proche), plusieurs ou même toutes les personnes non traitées (noyau).
- Les conditions de support commun et d'équilibre des échantillons doivent être respectées.

# Limites

# Sélection sur les variables observables

... et **uniquement** sur ces variables




# Sélection sur les variables observables

... et **uniquement** sur ces variables


—————→ Pas de facteur inobservé expliquant la sélection et modifiant la variable d'intérêt

—————→ Il faut avoir beaucoup de variables à disposition pour que cela puisse être vérifié


# Respect de la condition de support commun



# Respect de la condition de support commun




# Respect de la condition de support commun





# Respect de la condition de support commun



# Respect de la condition de support commun

